МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Компьютерные науки и прикладная математика»

Лабораторные работа
по курсу «Информационный поиск»

Выполнил: Гиголаев Антон Александрович
Группа: М8О-409Б-22
Преподаватель: Кухтичев Антон Алексеевич

Москва, 2026

1. Описание проекта

Работа охватывает полный учебный конвейер информационного поиска: краулинг HTML-страниц, хранение в MongoDB, построение булевого инвертированного индекса и выполнение запросов из CLI и через WEB-интерфейс.

Корпус собран из Русской Википедии (ru.wikipedia.org) и Habr (habr.com). Все документы на русском языке; сохраняются сырые HTML и метаданные краулинга (URL, дата, хэш контента, источник).

2. Состав и структура репозитория

Проект разбит на отдельные задачи:

- `task_2` - краулер (C, libcurl + MongoDB C driver);
- `task_3` - токенизация и закон Ципфа (C + Python график);
- `task_4` - индексатор (C++ без STL, MongoDB input);
- `task_5` - поиск (CLI + WEB-интерфейс, C++ без STL);
- `task_6` - единый LaTeX отчёт.

Запуск и оркестрация выполняются через Docker Compose.

Ключевые сервисы Docker Compose:

- `mongo` - MongoDB 7 (порт 27017);
- `crawler` - краулер;
- `indexer` - построение индекса (профиль `tools`);
- `web` - веб-интерфейс поиска (порт 8080);
- `cli` - CLI-поиск (профиль `tools`).

3. Корпус документов

Корпус собирается краулером и хранится в MongoDB в базе `infosearch`. Сырые страницы записываются в коллекцию `pages`, после чего отдельная утилита извлекает текст и сохраняет его в `articles`. Для построения индекса используется именно `articles` (поля `url`, `text`, `title`, `author`, `published_at`, `source`).

Всего собрано документов: **19960**.

4. Краулер

Краулер написан на C и использует MongoDB для хранения результатов и состояния обхода. Реализованы:

- ограничение доменов (allow_domains);

- пауза между запросами, лимит глубины/страниц;
- повторный обход и хранение хэша контента;
- сохранение сырых HTML-страниц для последующей индексации.

В Docker-окружении используется подключение `mongodb://mongo:27017/`.

5. Индексация и токенизация

Индексатор реализован на C++ без STL. На вход поступают документы из MongoDB, из HTML извлекается текст, затем выполняются токенизация и стемминг. После этого строится булев инвертированный индекс (термин → список документов).

Правила токенизации (как реализовано в коде):

- текст приводится к нижнему регистру;
- токен - непрерывная последовательность букв/цифр (латиница и кириллица в UTF-8);
- дефис и апостроф допускаются внутри токена, если окружены буквенно-цифровыми символами;
- HTML-теги отбрасываются, управляющие символы игнорируются.

Стемминг: простой суффиксный отсекатель для русских слов (набор распространённых окончаний).

Замеры производительности индексатора (команда `ir_indexer`, параметр `-limit`):

Docs	Terms	Tokens	Avg token len	Input, KB	Elapsed, s	Speed, KB/s
1000	19779	202545	8.92568	1412	0.25612	5513.8
5000	60829	1111798	8.96421	7793	1.00607	7746.5
10000	123792	4503575	9.54435	32132	3.89437	8250.8
19960	383124	20239398	9.67750	144089	20.81593	6922.1

Ниже приведены графики зависимости времени и скорости индексирования от объёма входных данных.

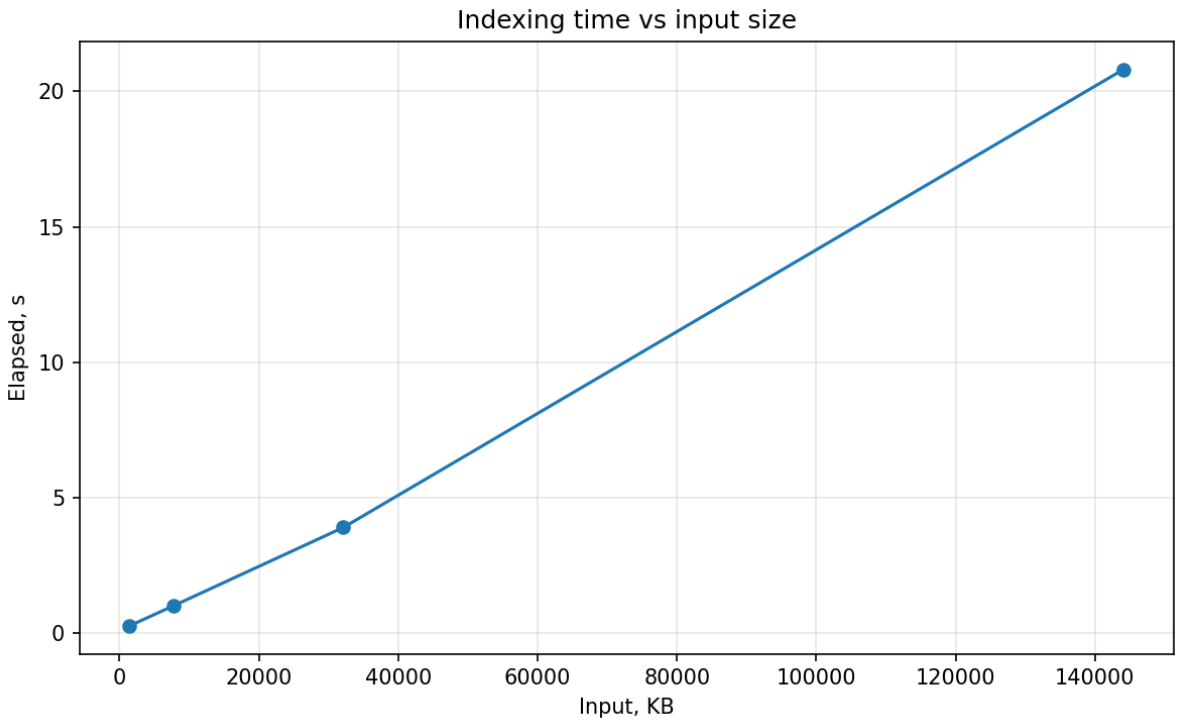

Рис. 1: Зависимость времени построения индекса от объёма входных данных.

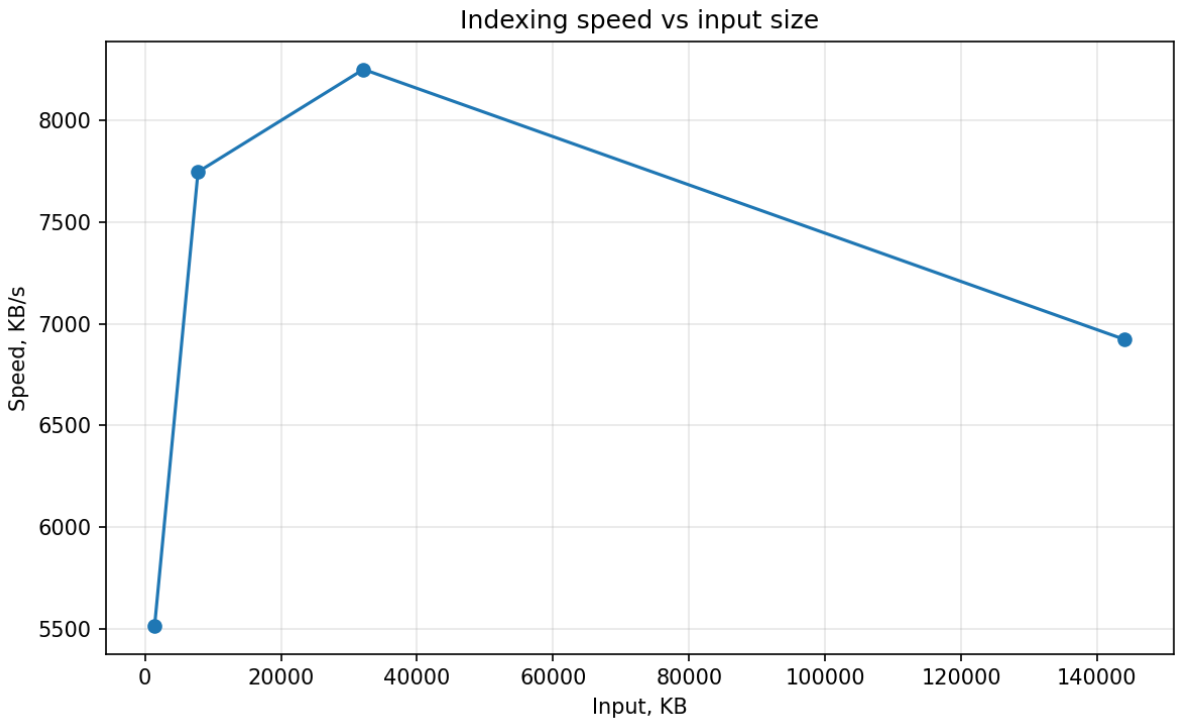

Рис. 2: Зависимость скорости токенизации+индексации от объёма входных данных.

6. Закон Ципфа

Для корпуса построено распределение терминов по частотам в лог-лог шкале. На верхних рангах ожидаемо находятся служебные слова русского языка (и, в, на). Для повышения качества поиска такие слова можно исключать через стоп-лист.

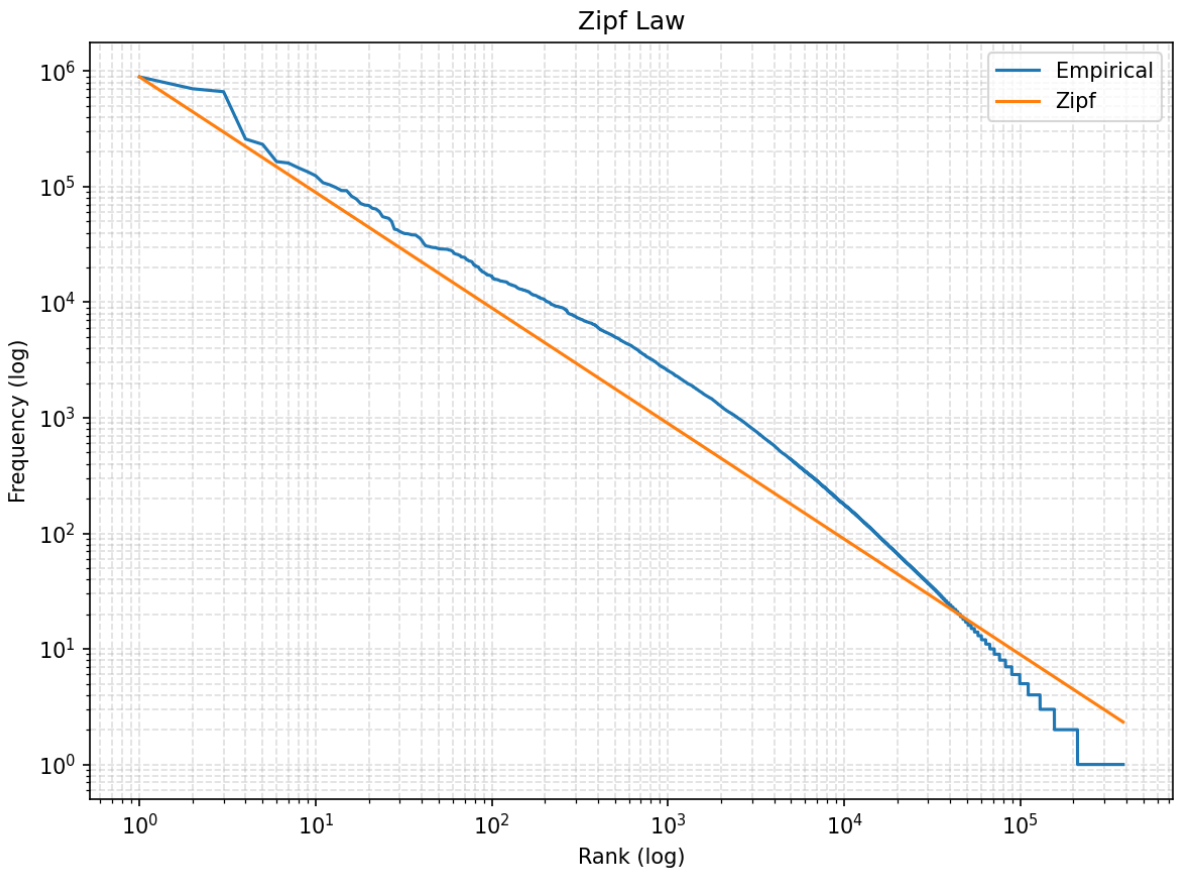

Рис. 3: Закон Ципфа и эмпирическое распределение терминов.

7. Булев поиск

Поисковая подсистема поддерживает булевы операторы and, or, not и скобки. Запрос вычисляется над postings-списками: пересечение (AND), объединение (OR) и разность (NOT). Приоритет операторов: NOT > AND > OR; скобки задают порядок вычисления.

Реализованы два интерфейса:

- WEB-интерфейс на порту 8080 (форма поиска и HTML-выдача);
- CLI-интерфейс.

8. Примеры работы WEB-интерфейса

Ниже показаны примеры запросов и полученной выдачи.

Boolean Search

Unity | Search

Results: 115

1. https://ru.wikipedia.org/wiki/%2813923%29_Peterhof
2. https://ru.wikipedia.org/wiki/%2813923%29_%D0%9F%D0%B5%D1%82%D0%B5%D1%80%D0%B3%D0%BE%D1%84
3. https://ru.wikipedia.org/wiki/...and_the_beat_goes_on%21
4. https://habr.com/ru/articles/1003546/
5. https://habr.com/ru/articles/1002624/
6. https://habr.com/ru/articles/1002078/
7. https://habr.com/ru/articles/1000700/
8. https://habr.com/ru/articles/1000568/
9. https://habr.com/ru/articles/1000506/
10. https://habr.com/ru/articles/996978/
11. https://habr.com/ru/articles/995258/
12. https://habr.com/ru/articles/992100/
13. https://habr.com/ru/articles/991704/
14. https://habr.com/ru/articles/991534/
15. https://habr.com/ru/articles/991518/
16. https://habr.com/ru/articles/991212/
17. https://habr.com/ru/articles/991054/
18. https://habr.com/ru/articles/990892/
19. https://habr.com/ru/articles/989028/
20. https://habr.com/ru/articles/988696/
21. https://habr.com/ru/articles/986388/
22. https://habr.com/ru/articles/986168/
23. https://habr.com/ru/articles/985454/
24. https://habr.com/ru/articles/985238/
25. https://habr.com/ru/articles/984944/
26. https://habr.com/ru/articles/984556/
27. https://habr.com/ru/articles/984360/
28. https://habr.com/ru/articles/984238/
29. https://habr.com/ru/articles/983524/
30. https://habr.com/ru/articles/983472/
31. https://habr.com/ru/articles/983416/
32. https://habr.com/ru/articles/983244/
33. https://habr.com/ru/articles/983008/
34. https://habr.com/ru/articles/982608/
35. https://habr.com/ru/articles/982558/
36. https://habr.com/ru/articles/982102/
37. https://habr.com/ru/articles/981308/
38. https://habr.com/ru/articles/980298/
39. https://habr.com/ru/articles/979416/
40. https://habr.com/ru/articles/979034/
41. https://habr.com/ru/articles/976938/
42. https://habr.com/ru/articles/976470/
43. https://habr.com/ru/articles/976424/
44. https://habr.com/ru/articles/976414/
45. https://habr.com/ru/articles/976258/
46. https://habr.com/ru/articles/975758/
47. https://habr.com/ru/articles/974020/
48. https://habr.com/ru/articles/973218/
49. https://habr.com/ru/articles/972926/
50. https://habr.com/ru/articles/972144/

Рис. 4: Пример простого запроса: Unity

Рис. 5: Пример булевого запроса: Unity и выстрел.

Boolean Search

Unity и не выстрел | Search

Results: 111

1. https://ru.wikipedia.org/wiki/%2813923%29_Peterhof
2. https://ru.wikipedia.org/wiki/%2813923%29_%D0%9F%D0%B5%D1%82%D0%B5%D1%80%D0%B3%D0%BE%D1%84
3. https://ru.wikipedia.org/wiki/...and_the_beat_goes_on%21
4. https://habr.com/ru/articles/1002624/
5. https://habr.com/ru/articles/1002078/
6. https://habr.com/ru/articles/1000700/
7. https://habr.com/ru/articles/1000568/
8. https://habr.com/ru/articles/1000506/
9. https://habr.com/ru/articles/996978/
10. https://habr.com/ru/articles/995258/
11. https://habr.com/ru/articles/992100/
12. https://habr.com/ru/articles/991704/
13. https://habr.com/ru/articles/991534/
14. https://habr.com/ru/articles/991518/
15. https://habr.com/ru/articles/991212/
16. https://habr.com/ru/articles/991054/
17. https://habr.com/ru/articles/990892/
18. https://habr.com/ru/articles/989028/
19. https://habr.com/ru/articles/988696/
20. https://habr.com/ru/articles/986388/
21. https://habr.com/ru/articles/986168/
22. https://habr.com/ru/articles/985454/
23. https://habr.com/ru/articles/985238/
24. https://habr.com/ru/articles/984944/
25. https://habr.com/ru/articles/984556/
26. https://habr.com/ru/articles/984360/
27. https://habr.com/ru/articles/984238/
28. https://habr.com/ru/articles/983524/
29. https://habr.com/ru/articles/983472/
30. https://habr.com/ru/articles/983416/
31. https://habr.com/ru/articles/983244/
32. https://habr.com/ru/articles/983008/
33. https://habr.com/ru/articles/982608/
34. https://habr.com/ru/articles/982558/
35. https://habr.com/ru/articles/982102/
36. https://habr.com/ru/articles/981308/
37. https://habr.com/ru/articles/980298/
38. https://habr.com/ru/articles/979416/
39. https://habr.com/ru/articles/979034/
40. https://habr.com/ru/articles/976938/
41. https://habr.com/ru/articles/976470/
42. https://habr.com/ru/articles/976424/
43. https://habr.com/ru/articles/976414/
44. https://habr.com/ru/articles/976258/
45. https://habr.com/ru/articles/975758/
46. https://habr.com/ru/articles/974020/
47. https://habr.com/ru/articles/973218/
48. https://habr.com/ru/articles/972926/
49. https://habr.com/ru/articles/972144/
50. https://habr.com/ru/articles/971490/

Рис. 6: Пример булевого запроса: Unity и не выстрел

9. Вывод

Выполнен полный пайплайн информационного поиска: сбор корпуса (краулер), построение инвертированного булевого индекса и выполнение запросов через WEB и CLI. Проведены замеры производительности индексирования на разных объёмах входных данных, а также подготовлена статистика для анализа закона Ципфа.